

REPORTE TÉCNICO: ESTRATEGIA

INTEGRAL DE RETENCIÓN

FINANCEGUARD

Proyecto Integrador #4

- Autor: Matias Damian Gutierrez
- Fecha de Entrega: 09/01/2026

Este documento consolida la estrategia analítica para reducir la fuga de clientes (Churn). A través de un proceso evolutivo de cuatro etapas, hemos logrado identificar los patrones de abandono, predecir con alta precisión qué clientes están en riesgo y diseñar una estrategia de segmentación que maximiza el retorno económico del banco.


FASE 1: DIAGNÓSTICO Y COMPRENSIÓN DEL FENÓMENO

(Fuente: Notebook 1_EDA_RegresionLogistica)

1.1 Hallazgos del Exploratorio de Datos (EDA)

El análisis inicial de la base de clientes reveló que la fuga no es un evento aleatorio, sino que está fuertemente correlacionada con variables específicas.

- Correlaciones: Existe una relación positiva fuerte entre la Edad y el abandono.
- Actividad: Los clientes inactivos (`IsActiveMember = 0`) tienen una probabilidad de fuga significativamente mayor.
- Geografía: Alemania presenta una tasa de fuga estructuralmente más alta que Francia o España.



1.2 Línea Base: Regresión Logística

Se utilizó un modelo lineal para establecer un punto de partida. Si bien la exactitud global fue aceptable (~81%), el modelo falló en la métrica de Recall, dejando escapar a muchos clientes que realmente se iban a marchar. Esto justificó la necesidad de modelos más complejos.

FASE 2: SELECCIÓN DEL MODELO PREDICTIVO (SUPERVISADO)

(Fuente: Notebook 2_GradientBoosting_Optimizacion)

2.1 Comparativa Técnica de Modelos


Para superar las limitaciones lineales, entrenamos y optimizamos modelos de ensemble (Gradient Boosting). A continuación, se presenta la tabla comparativa que respalda la elección del modelo final:

Tabla 1: Comparativa de Rendimiento - Modelos Supervisados

Métrica / Característica	Regresión Logística (Baseline)	Gradient Boosting (Modelo Final - CatBoost/XGB)	Análisis de Mejora
Tipo de Algoritmo	Lineal (Estadístico Clásico)	Ensamble de Árboles (No Lineal)	Mayor capacidad para captar patrones complejos.
ROC-AUC (Calidad)	~0.76 - 0.77	~0.86 - 0.88	+12% de mejora en discriminación general.
Recall (Detección)	Bajo (Muchos Falsos Negativos)	Alto (Optimizado)	Crucial: Identificamos más clientes en riesgo real.
Interpretabilidad	Coeficientes (+/-)	Feature Importance	Pasamos de "signo" a "ranking de importancia".
Conclusión	Útil para diagnóstico	Elegido para Producción	El modelo Boosting justifica la inversión computacional.

2.2 Variables Determinantes (Feature Importance)

El modelo ganador no es una "caja negra"; nos indica claramente qué factores pesan más en la decisión de un cliente.



- Descripción: Muestra que la Edad, el Número de Productos y el Balance son las barras más largas, indicando que son los drivers principales del churn.

FASE 3: SEGMENTACIÓN AVANZADA (CLUSTERING)

(Fuente: Notebook 3_AprendisajeNoSupervisado)

3.1 Estrategia de Granularidad (K-Means = 4)


Para evitar generalizaciones excesivas, se definió un $K=4$ en el algoritmo K-Means. Esto nos permite dividir la cartera de clientes en cuatro perfiles psicológicos y financieros bien diferenciados, permitiendo asignar presupuestos de retención de manera más eficiente que una simple división binaria (Se va / No se va).

3.2 Perfiles Detectados y Acciones

El algoritmo segregó la base de datos en los siguientes grupos (verificar características en el gráfico de dispersión y tablas de promedios del notebook):

- Cluster 0 - "Clientes VIP en Riesgo" (Prioridad Alta):
 - Características: Generalmente clientes de mayor edad (45+), con balances altos y productos activos.
 - Acción: Retención Personalizada. Llamada de un ejecutivo de cuenta senior. El costo de perderlos es el más alto.
- Cluster 1 - "Jóvenes Inactivos" (Riesgo Medio):
 - Características: Clientes jóvenes, saldo bajo o nulo, inactivos recientemente.
 - Acción: Reactivación Digital. Campañas de email marketing automatizado (bajo costo) para incentivar el uso de la app.
- Cluster 2 - "Usuarios Estándar Leales" (Riesgo Bajo):

- Características: Edad media, varios productos, activos.
- Acción: Fidelización (Cross-Selling). Ofrecerles tarjetas de crédito o seguros. No gastar presupuesto en retención, sino en venta cruzada.
- Cluster 3 - "Nuevos o Transaccionales":
 - Características: Antigüedad baja, comportamiento variable.
 - Acción: Onboarding. Nutrir la relación para convertirlos en VIPs futuros.



- Descripción: Muestra visualmente cómo los puntos (clientes) se separan en grupos de colores distintos, validando que existen segmentos diferenciados.


FASE 4: ESTRATEGIA DE NEGOCIO Y ROI

(Fuente: Notebook 4_Extra_Credit)

4.1 Optimización Financiera (Threshold Tuning)

El paso final conecta la ciencia de datos con el dinero. En lugar de usar el umbral estándar (0.5), ajustamos el punto de corte del modelo basándonos en la matriz de costos del banco.

- Estrategia: Reducir el umbral (ej. a 0.30) permite capturar a casi la totalidad de los clientes en fuga.
- Costo-Beneficio: Aunque esto incrementa ligeramente los falsos positivos (contactar a quien no se iba a ir), el costo de la campaña es mucho menor que el costo de perder a un cliente de alto valor.



- Descripción: El punto más alto de la curva marca el umbral exacto donde el banco gana más dinero.

CONCLUSIÓN EJECUTIVA: ANÁLISIS DE VIABILIDAD (ROI)

5.1 ¿Vale la pena la implementación?

Para determinar la viabilidad del proyecto, realizamos un análisis de costo-beneficio comparando la estrategia actual (reactiva) vs. la estrategia predictiva propuesta.

Escenario: Supongamos una cartera de 10,000 clientes con una tasa de fuga natural del 20% (2,000 clientes se irían).

- Costo de perder un cliente (LTV perdido): \$500 USD (promedio).
- Costo de campaña de retención (Incentivo): \$50 USD por cliente contactado.

5.2 Comparativa de Estrategias

Estrategia	Acción	Costo de Campaña	Clientes Salvados (Est.)	Pérdida por Fuga	Costo Total para el Banco
1. Sin Modelo	No hacer nada.	\$0	0	\$1,000,000	\$1,000,000 (Pérdida Máx)
2. Campaña Masiva	Contactar a todos (10k).	\$500,000	1,000 (50% efec.)	\$500,000	\$1,000,000 (Ineficiente)

3. Modelo Propuesto	Contactar solo al Top 25% (Riesgo Alto).	\$125,000	~850 (Alta precisión)	\$575,000	\$700,000 (Opción Óptima)
---------------------	--	-----------	-----------------------	-----------	---------------------------

5.3 Veredicto Final

La implementación del modelo predictivo (Gradient Boosting) sumado a la segmentación focalizada (4 Clusters) genera un ahorro neto estimado de \$300,000 USD por cada 10,000 clientes gestionados, reduciendo el gasto operativo de marketing en un 75% al no contactar a clientes seguros.